Prepoznavanje tumora iz MRI slika ljudskog mozga

1st Lucija Topolko
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
lucija.topolko@fer.hr

2nd Julijana Kolarec
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
julijana.kolarec@fer.hr

3rd Karla Budimir
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
karla.budimir@fer.hr

4th Carla Goluža
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
carla.goluza@fer.hr

5th Dora Bilić Pavlinović
Fakultet elektrotehnike i računarstva
Zagreb, Hrvatska
dora.bilic-pavlinovic@fer.hr

***Sažetak*—U ovom se radu razmatra primjena konvolucijskih neuronskih mreža za višeklasnu klasifikaciju tumora na MRI slikama mozga. Evaluirani su pristupi koji uključuju prednaučeni EfficientNet model primijenjen metodom transfer učenja, konvolucijsku neuronsku mrežu temeljenu na MBConv blokovima te konvolucijsku neuronsku mrežu s dilatiranim konvolucijama. Dodatno je ispitan utjecaj prethodne segmentacije regije interesa (ROI) na uspješnost klasifikacije. Usporedba modela provedena je korištenjem standardnih evaluacijskih mjera, a rezultati pokazuju da predloženi pristupi omogućuju pouzdanu klasifikaciju različitih tipova tumora mozga te da izbor arhitekture neuronske mreže, kao i način obrade ulaznih podataka, značajno utječe na postignute performanse.**

***Ključne riječi*—MRI mozga, tumori mozga, konvolucijske neuronske mreže, EfficientNet, MBConv, dilatirane konvolucije, regija interesa (ROI), duboko učenje**

I. Uvod

Tumori mozga jedan su od najozbiljnijih zdravstvenih izazova suvremene medicine. Svake godine dijagnosticira se više stotina tisuća novih slučajeva primarnih tumora mozga, a stopa smrtnosti zabrinjavajuće je visoka. Rana i precizna dijagnoza ključna je za pravovremeno liječenje i povećanje šansi za preživljavanje pacijenata. Tumori mozga mogu biti benigni ili maligni, pri čemu se razlikuje nekoliko osnovnih tipova. Gliomi su najčešći primarni tumori mozga koji nastaju iz glijalnih stanica i mogu biti različitih stupnjeva malignosti. Meningeomi su tumori koji nastaju iz ovojnica mozga (meningea) i najčešće su benigni, ali mogu uzrokovati ozbiljne simptome zbog pritiska na moždano tkivo. Tumori hipofize razvijaju se u hipofiznoj žlijezdi i mogu narušiti hormonalnu ravnotežu organizma. [1] Svaki od ovih tumora zahtijeva specifičan pristup u dijagnostici i liječenju.

U ovom radu istražuje se primjena konvolucijskih neuronskih mreža za višeklasnu klasifikaciju tumora mozga na MRI snimkama. Eksperimenti su provedeni na javno dostupnom skupu podataka MRI snimki mozga koji sadrži četiri klase: bez tumora, gliom, meningeom i tumor hipofize. Analizirano je više pristupa dubokog učenja, uključujući prednaučeni EfficientNet model primijenjen metodom transfer učenja, prilagođenu konvolucijsku neuronsku mrežu temeljenu na MBConv blokovima te konvolucijsku neuronsku mrežu s dilatiranim konvolucijama treniranu od početka. Osim modela treniranih na originalnim slikama, eksperimentalno je razmotrena i varijanta s prethodnom ekstrakcijom regije interesa (ROI). Učinkovitost modela evaluirana je pomoću točnosti, preciznosti, odziva, F1-mjere i konfuzijske matrice. Dobiveni rezultati potvrđuju da konvolucijske neuronske mreže predstavljaju učinkovit pristup za automatsku klasifikaciju tumora mozga, pri čemu izbor arhitekture i reprezentacije ulaznih podataka ima značajan utjecaj na ponašanje modela.

II. Pregled postojećih rješenja

Razvoj tumora na mozgu može dovesti do teških zdravstvenih posljedica poput gubitka pamćenja i poremećaja motorike. Zbog toga je ključna rana dijagnoza tumora mozga. U posljednjih nekoliko godina, sve češće se koriste metode dubokog učenja za prepoznavanje i klasifikaciju tumora mozga iz MRI slika.

Pregledni rad [2] koji obuhvaća 60 znanstvenih članaka objavljenih između 2020. i 2024. godine, analizira širok raspon pristupa korištenja dubokog učenja, uključujući *transfer-learning*, auto-enkoder, transformatore i mehanizme pažnje. Rezultatima je pokazano da konvolucijske neuronske mreže (CNN) dobivaju značajno točnije rezultate u odnosu na ostale metode strojnog učenja te da predstavljaju dominantan smjer budućih istraživanja u području kliničke dijagnostike.

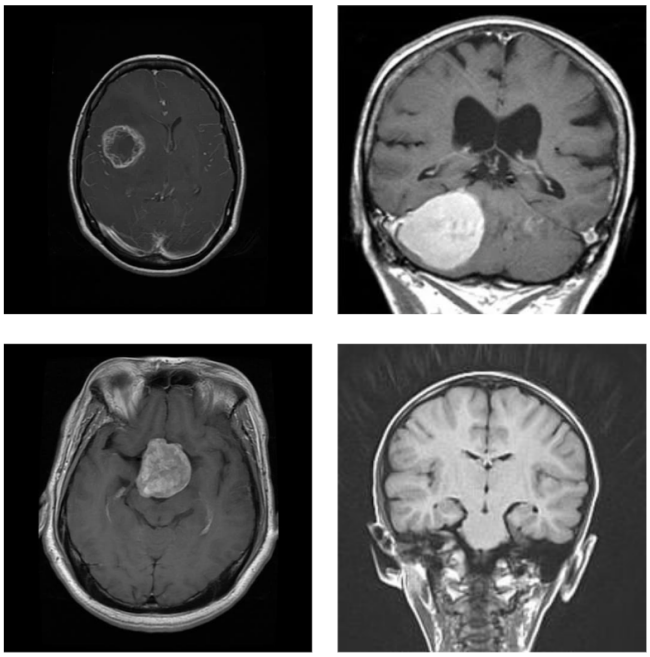
U istraživanju [3], opisani su rezultati dobiveni novom CNN arhitekturom MIDNet18, koja je uspoređena s VGG16 arhitekturom u zadatku binarne klasifikacije MRI slike mozga na one s i bez tumora. Istraživanje je pokazalo da se pomoću MIDNet18 postigla iznimno visoka točnost od 98,7%, dok je VGG16 ostvario svega 50% točnosti. Statističkom analizom potvrđena je značajna prednost predloženog modela ($p < 0.001$), što ukazuje na važnost arhitektura posebno dizajniranih za analizu MRI slika u odnosu na generičke modele.

Drugo istraživanje, [4], temeljilo se na segmentaciji tumora mozga pomoću poboljšane rezidualne mreže (Improved ResNet). Poboljšanje predloženog modela postignuto je optimizacijom protoka informacija kroz mrežu, unapređenjem rezidualnih blokova i projekcijskih prečaca. Eksperimentalno je pokazano da poboljšani ResNet ostvaruje 10% bolje rezultate

u točnosti, odzivu i F-mjeri u usporedbi s klasničnom CNN i potpuno konvolucijskim neuronskim mrežama (FCN). Uz povećanu preciznost, pokazani su i smanjeni računski troškovi te brže učenja.
U istraživanju [5], uspoređena je učinkovitost 2D CNN modela, konvolucijskog auto-enkodera i nekoliko klasičnih metoda strojnog učenja u klasifikaciji MRI slika mozga u 4 kategorije: gliom, meningeom, tumor hipofize i zdravi mozak. Predloženi 2D CNN postigao je točnost treniranja od 96,47%, dok je auto-enkoder ostvario 95,63% točnosti. Za oba modela, površina ispod ROC krivulje bila je između 0,99 i 1, što ukazuje na izvrsnu sposobnost razdvajanja klasa. U ovom slučaju, klasične metode strojnog učenja pokazale su znatno slabije rezultate. CNN postigao je maksimalnu točnost od 86%, dok je MLP ostvario samo 28% točnosti.
Javno dostupni "Brain Tumor MRI Dataset" korišten je u brojnim radovima o detekciji i klasifikaciji tumora mozga iz MRI slika. U radu [6] primijenjen je prilagođeni konvolucijski neuronski model i unaprijed trenirani ResNet18 za višeklasnu klasifikaciju tumora (gliom, meningeom, tumor hipofize i zdravi mozak), pri čemu je postignuta vrlo visoka točnost od 99,7%. Slično tome, u radu prikazanom na ResearchGateu [7] korišten je Xception model, koji je treniran pomoću istog skupa podataka te je ostvario točnost veću od 99% uz visoke vrijednosti preciznosti.
U radu [8] pokazano je da i jednostavnije, prilagođene CNN mreže mogu postići konkurentne rezultate u odnosu na složenije modele kao što su VGG16 i ResNet18 s točnošću većom od 99%. Nadalje, u radu [9] predložen je hibridni model Squeezed-Eff-Net koji kombinira EfficientNet i SqueezeNet arhitekture. Na taj način su se, uz ručno izdvojene značajke, postigle točnosti između 98,9% i 99,1%.
Sveukupno, istraživanja jasno pokazuju da CNN arhitrkture, posebno one prilagođene za analizu medicinskih slika te poboljšane rezidualne mreže, postižu znatno bolje rezultate u detektiranju i klasifikaciji tumora na mozgu iz MRI slika u odnosu na klasične metode strojnog učenja. Dobivene točnosti kreću se u rasponu od 95% do 99%, što ukazuje da duboko učenje predstavlja pouzdan i učinkovit alat koji se može primijeniti u kliničkoj dijagnostici.

III. Opis podataka

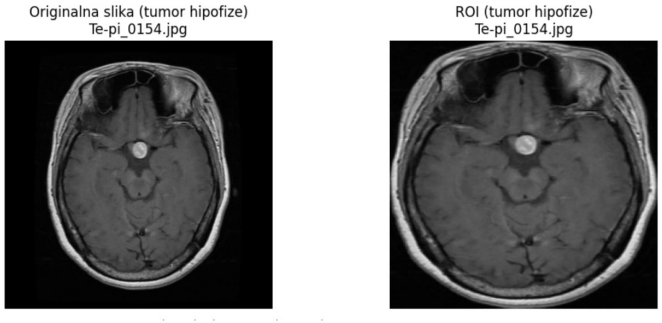
Za ovaj projekt korišten je javno dostupan skup podataka Brain Tumor MRI Dataset objavljen na platformi Kaggle. Skup se sastoji od MRI slika mozga i služi za istraživanja usmjerenim na detekciju i klasifikaciju tumora mozga primjenom metoda strojnog i dubokog učenja.
Skup podataka sadrži 7023 MRI slika mozga, koje su organizirane u četiri klase: gliom, meningeom, tumor hipofize (*pituitary*) i zdravi mozak (*no tumor*). Takva struktura skupa omogućuje provođenje klasifikacije, što modelu omogućuje da osim prepoznavanja samog tumora, može i razlikovati tip tumora mozga. Slike su pohranjene u JPEG formatu i predstavljaju MRI presjeke mozga.
Raspodjela slika među klasama relativno je uravnotežena, što je važno za stabilno treniranje modela i smanjuje pristranost prema pojedinim klasama. Skup je podijeljen na skup za treniranje, validaciju i testiranje, pri čemu skup za treniranje sadrži 4856, skup za validaciju 856, a skup za testiranje 1311 slika.
Glavna prednost ovog skupa je što je javno dostupan i široko primijenjen u literaturi. Uz to, relativno velik broj slika i raznolikost klasa čine skup prikladnim za treniranje i evaluaciju različitih CNN arhitektura i drugih modela dubokog učenja u području analize medicinskih slika. Primjeri slika iz skupa prikazani su na slici 1.



Slika 1. Primjeri MRI slika iz skupa.

IV. Obrada podataka

Prije korištenja podataka za učenje modela, potrebno je napraviti predobradu MRI slika. Predobrada uključuje promjenu dimenzija slike na standardnu veličinu, normalizaciju intenziteta piksela te augmentaciju podataka (rotacija, preslikavanje i skaliranje). Budući da skup podataka ne sadrži ručne oznake tumorskih područja, on je primarno namijenjen za klasifikaciju, a ne precizne segmentacije tumora.
U svim eksperimentima ulazne slike su skalirane na rezoluciju 224×224 piksela, čime je osigurana konzistentna prostorna dimenzija ulaza i usporedivost rezultata među modelima. Tijekom treniranja svih modela korištena je horizontalna augmentacija (horizontal flip) radi povećanja robusnosti na orijentaciju slike. Kod konvolucijskih mreža treniranih od početka dodatno je primijenjena nasumična rotacija do ±10°, s ciljem povećanja generalizacije i smanjenja prenaučavanja, budući da ovi modeli nemaju prethodno naučene značajke.
Za EfficientNet modele nije korištena rotacija, već samo blaga augmentacija, uz primjenu standardne normalizacije speci-



Slika 2. MRI slika prije i poslije ROI ekstrakcije

fične za EfficientNet (*preprocess_input*), u skladu s transfer-učenjem.

ROI varijanta EfficientNet modela uključuje dodatni korak ekstrakcije regije interesa (ROI) pomoću klasičnih metoda obrade slike (*OpenCV*), pri čemu se iz slike izdvaja područje mozga na temelju binarizacije i morfoloških operacija. Nakon ROI ekstrakcije, slike se ponovno skaliraju na 224×224 piksela te prolaze identičan proces normalizacije i treniranja kao i originalni EfficientNet model.

Primjer slike prije i poslije ROI ekstrakcije prikazan je na slici 6.

Normalizacija je kod modela treniranih od početka provedena po kanalu s konstantnim srednjim vrijednostima i standardnim devijacijama, dok EfficientNet modeli koriste ugrađenu normalizaciju prilagođenu prednaučenim težinama.

V. Rješenja projektnog tima

U ovom radu za klasifikaciju tumora mozga uspoređene su tri konvolucijske neuronske mreže, jedna je duboka mreža EfficientNet-B3, a dvije su napravljene *iz nule*.

A. Prva mreža

Prva korištena mreža je konvolucijska neuronska mreža implementirana u PyTorch okviru, dizajnirana kao kompromis između jednostavne CNN arhitekture i složenijih modela. Temelji se na hijerarhijskoj strukturi konvolucijskih blokova s postupnim povećanjem broja kanala te uključuje mehanizme za stabilnije učenje i bolju generalizaciju.

Model mreže sastoji se od četiri konvolucijska bloka. Prva tri bloka koriste standardne 3x3 konvolucije s dva uzastopna sloja unutar svakog bloka, praćena *batch*-normalizacijom, ReLU aktivacijskom funkcijom i *max-pooling* slojem za smanjenje prostorne rezolucije. Broj kanala se postupno povećava od 32, 64 do 128, čime se omogućuje učenje sve složenijih prostornih značajki MRI slika.

Četvrti blok uvodi konvolucije s faktorom dilatacije 2, čime se povećava receptivno polje mreže bez dodatnog smanjenja prostorne rezolucije. To omogućuje modelu da zahvati širi kontekst slike i bolje prepozna globalne obrasce, što je posebno važno kod MRI snimaka gdje prostorni odnos tumora i okolnog tkiva ima ključnu ulogu u klasifikaciji.

Završni dio mreže uključuje sloj adaptivnog prosječnog sažimanja (engl. *Adaptive Average Pooling*), nakon kojeg slijede potpuno povezani slojevi s *dropout* regularizacijom od 40 % kako bi se smanjila mogućnost prenaučenosti. Završni sloj s četiri izlazna neurona omogućuje višeklasnu klasifikaciju tumora mozga pomoću *softmax* funkcije.

B. EfficientNet-B3

EfficientNet-B3 temelji se na arhitekturi EfficientNet-B0, a dobiva se primjenom *compound scaling* metode kojom se povećavaju dubina, širina i ulazna rezolucija mreže.

Arhitektura se sastoji od početnog konvolucijskog sloja, niza MBConv blokova (engl. *Mobile Inverted Bottleneck Convolution*) s različitim faktorima ekspanzije i veličinama jezgri te završnog konvolucijskog sloja. Za ovaj projekt korišten je model EfficientNet-B3 bez završnog sloja za klasifikaciju (*include_top = False*), pri čemu su svi slojevi mreže otključani kako bi se omogućilo potpuno fino podešavanje za MRI slike. Slike su skalirane na 224 x 224 piksela zbog ograničenja memorije i računalnih resursa, pri čemu je zadržana unutarnja struktura i dubina mreže.

Na izlazu osnovne mreže dodani su prilagođeni slojevi za klasifikaciju: normalizacija, potpuno povezani sloj s 256 neurona, kombinacija L1 i L2 regularizacije te *dropout* sloj s vjerojatnošću od 45%. Završni sloj koristi *softmax* aktivacijsku funkciju za višeklasnu klasifikaciju tumora.

Struktura korištene EfficientNet-B3 arhitekture prikazana je u tablici I.

Tablica I
Arhitektura EfficientNet-B3

Faza (i)	Operator	Rezolucija (H × W)	Broj kanala	Broj slojeva
1	Conv 3×3	224 × 224	40	1
2	MBConv1, k3×3	112 × 112	24	2
3	MBConv6, k3×3	112 × 112	32	3
4	MBConv6, k5×5	56 × 56	48	3
5	MBConv6, k3×3	28 × 28	96	4
6	MBConv6, k5×5	28 × 28	136	5
7	MBConv6, k5×5	14 × 14	232	6
8	MBConv6, k3×3	7 × 7	384	2
9	Conv 1×1 + Pooling	7 × 7	1536	1

C. Pojednostavljena EfficientNet mreža

Ovaj model implementiran je u PyTorchu i treniran od početka, bez korištenja prijenosnog učenja ili prethodno naučenih težina. Arhitektura koristi MBConv blokove i Squeeze-and-Excitation (SE) mehanizam, inspirirana EfficientNetom, kako bi učinkovito kombinirala širinu, dubinu i složenost mreže.

Ulazne slike skalirane su na 224×224 piksela, a tijekom treniranja primijenjene su standardne tehnike augmentacije podataka, uključujući horizontalno zrcaljenje i rotaciju od ±10°, kako bi se povećala robusnost modela na varijacije u orijentaciji i položaju tumora.

Za treniranje je korištena funkcija gubitka *CrossEntropy Loss* i optimizator *Adam* s početnom stopom učenja 0,0003. Treniranje je provedeno kroz 15 epoha, uz praćenje točnosti na skupu za trening i validaciju. Evaluacija modela provedena je na testnom skupu podataka.
U usporedbi s drugim modelima, ovaj model predstavlja kompromis između jednostavnih klasičnih CNN arhitektura i složenijih dubokih modela, zahvaljujući upotrebi MBConv blokova i SE mehanizma inspiriranih EfficientNetom.

Pregled razlika između modela prikazan je u tablici II.

Tablica II
USPOREDBA MODELA

Karakteristika	Pri model	**Pojednostavljeni EfficientNet**	**EfficientNet-B3**
Arhitektura	CNN s konvolucijskim blokovima	Klasični CNN	Duboka, optimizirana
Prijenosno učenje	Ne	Ne	Da (ImageNet)
Regularizacija	Dropout (0.4)	Osnovna	L1 + L2 + Dropout
Augmentacija	Agresivnija (flip + rotacija)	Agresivnija (flip + rotacija)	Umjerena (horizontalni flip)
Strategija učenja	Treniranje od nule	Treniranje od nule	Fino podešavanje svih slojeva

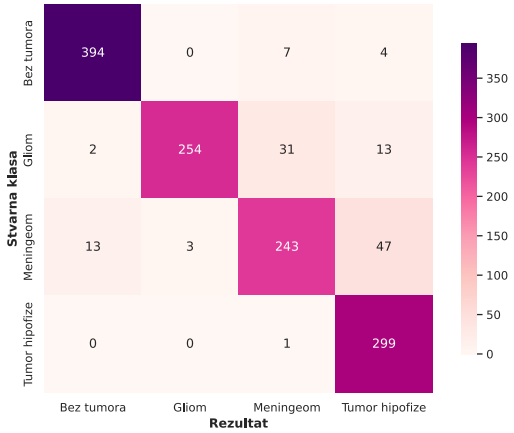
VI. REZULTATI

U tablici III prikazane su vrijednosti evaluacijskih mjera za tri testirana modela. Preciznost, odziv i F1-mjera izraženi kao makro prosjeci (engl. *macro average*) čime se svakoj klasi daje jednaka važnost, bez obzira na broj uzoraka. Na temelju rezultata vidljivo je da sva tri modela postižu visoke vrijednosti mjera evaluacije te je primjetan progresivan rast uspješnosti: prvi model ostvario je točnost od 90.77%, dok je pojednostavljeni EfficientNet značajno poboljšao rezultat na 96.80%. Najbolje performanse očekivano je pružio model EfficientNet-B3 s točnošću od visokih 98,70% i gotovo ujednačenim vrijednostima svih makro mjera.

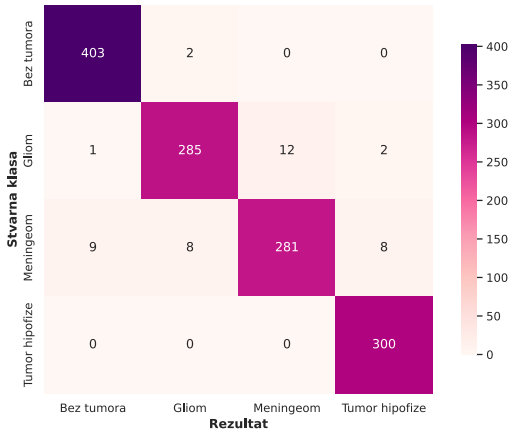
Postupno poboljšanje klasifikacijskih sposobnosti jasno je vidljivo i na prikazanim matricama zabune na slikama 3, 4 i 5. Vizualna usporedba triju matrica otkriva jasnu redukciju broja pogrešno klasificiranih primjera (smanjuju se vrijednosti elemenata izvan dijagonale). Takvi rezultati potvrđuju da primijenjene optimizacije i dubina mreže izravno pridonose boljem razlučivanju različitih tipova tumora.

Tablica III
REZULTATI

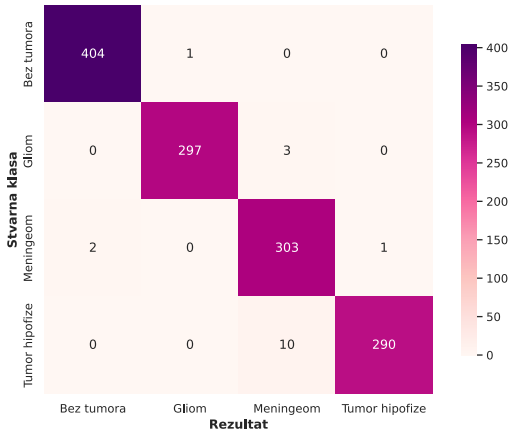
Mjere evaluacije	**Model**		
	Prvi model	Pojednostavljeni EfficientNet	EfficientNet-B3
Točnost	0.9077	0.9680	0.9870
Preciznost	0.9093	0.9672	0.9868
Odziv	0.9026	0.9658	0.9861
Mjera $F1$	0.9021	0.9663	0.9863



Slika 3. Matrica zabune prvog modela



Slika 4. Matrica zabune pojednostavljenog EfficientNet modela



Slika 5. Matrica zabune modela EfficientNet-B3

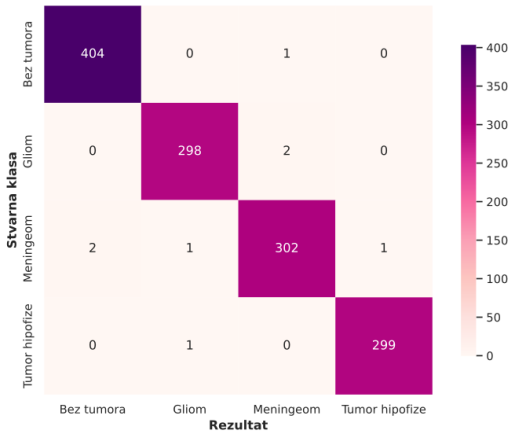
Arhitektura EfficientNetB3 istrenirana je na originalnim MRI slikama mozga, ali i na slikama koje su dobivene automatskom ekstrakcijom relevantne regije mozga. ROI (engl. *Region of Interest*) izdvaja regiju mozga prije klasifikacije, odnosno ne označava točno gdje je tumor, već označava cijeli mozak tako uklanjajući pozadinu i šum. Treniranje je izvršeno pod istim uvjetima (arhitektura, hiperparametri, broj epoha i podjela podataka) pa je time osigurana pravedna usporedba.

S originalnim slikama postignuta je ukupna točnost približno 99% na testnom skupu. Iako je ukupna točnost bila visoka, analiza po klasama pokazala je blage razlike u performansama. Posebno se istaknula klasa meningeom za koju je preciznost iznosila 0.96, dok je tumor hipofize klasa imala niži odziv, 0.97.

Na ROI slikama također je ukupna točnost približno 99%, ali uz znatno stabilnije ponašanje tijekom treniranja. Validacijska točnost rasla je brže i ravnomjernije, a krivulje gubitka nisu pokazivale nagle oscilacije. Analiza po klasama pokazala je poboljšanje. Preciznost i odziv za meningeom porasli su na 0.99, dok je tumor hipofize postigao savršen odziv (1.00). Ostvarene vrijednosti evaluacijskih mjera modela EfficientNet treniranog na ROI skupu slika prikazane su u tablici IV, a odlična klasifikacija vidljiva je na matrici zabune (slika 6). Sve klase imale su uravnotežene F1-mjere, što ukazuje na konzistentno učenje bez favoriziranja pojedinih klasa.

Tablica IV
REZULTATI NAKON ROI EKSTRAKCIJE

Mjere evaluacije	**Model**
	EfficientNet-b3
Točnost	0.9939
Preciznost	0.9938
Odziv	0.9936
Mjera $F1$	0.9937



Slika 6. Matrica zabune modela EfficientNet-B3 s ROI slikama

VII. ZAKLJUČAK

U ovom radu istražena je primjena konvolucijskih neuronskih mreža za automatsku klasifikaciju tumora mozga na MRI snimkama, s ciljem usporedbe različitih arhitektura i strategija učenja. Analizirana su tri modela: prilagođena konvolucijska mreža s dilatiranim konvolucijama, pojednostavljena EfficientNet arhitektura trenirana od početka te duboki EfficientNet-B3 model temeljen na prijenosnom učenju. Svi modeli evaluirani su na istom skupu podataka i prema istim mjernim kriterijima, čime je osigurana objektivna usporedba rezultata. Pokazalo se da EfficientNetB3 model s ROI slikama smanjuje pogrešne klasifikacije u odnosu na isti model s originalnim slikama. To je posebno važno u klinički osjetljivim slučajevima i omogućuje robusniju generalizaciju na neviđene podatke.

Dobiveni rezultati jasno pokazuju da dubina mreže, kvaliteta naučenih značajki i primjena prijenosnog učenja imaju značajan utjecaj na uspješnost klasifikacije. Najbolje performanse ostvario je EfficientNet-B3 model s točnošću od 98,70%, uz visoke i uravnotežene vrijednosti preciznosti, odziva i F1-mjere za sve klase. Pojednostavljena EfficientNet mreža također je postigla vrlo dobre rezultate, čime je potvrđeno da i modeli trenirani od početka mogu biti iznimno učinkoviti ako su pravilno dizajnirani. Najjednostavniji CNN model, iako slabiji u odnosu na ostale, i dalje je pokazao zadovoljavajuću razinu uspješnosti te poslužio kao dobra referentna točka.

Sveukupno, rezultati ovog rada potvrđuju da duboko učenje ima velik potencijal u području prepoznavanja tumora mozga te predstavlja važan korak prema pouzdanijim i bržim dijagnostičkim sustavima.

LITERATURA

[1] „Brain Tumor Types“, Ivy Brain Tumor Center. Pristupljeno: 18. siječanj 2026. Dostupno na: https://www.ivybraintumorcenter.org/brain-tumor-care/brain-tumor-types/

[2] S. Bouhafra i H. El Bahi, „Deep Learning Approaches for Brain Tumor Detection and Classification Using MRI Images (2020 to 2024): A Systematic Review“, *J Digit Imaging. Inform. med.*, sv. 38, izd. 3, str. 1403–1433, ruj. 2024, doi: 10.1007/s10278-024-01283-8.

[3] „Brain tumour classification of Magnetic resonance images using a novel CNN based Medical Image Analysis and Detection network in comparison with VGG16“, *JPTCP*, sv. 28, izd. 2, sij. 2022, doi: 10.47750/jptcp.2022.873.

[4] M. Aggarwal, A. K. Tiwari, M. P. Sarathi, i A. Bijalwan, „An early detection and segmentation of Brain Tumor using Deep Neural Network“, *BMC Med Inform Decis Mak*, sv. 23, izd. 1, str. 78, tra. 2023, doi: 10.1186/s12911-023-02174-8

[5] S. Saeedi, S. Rezayi, H. Keshavarz, i S. R. Niakan Kalhori, „MRI-based brain tumor detection using convolutional deep learning methods and chosen machine learning techniques“, *BMC Med Inform Decis Mak*, sv. 23, izd. 1, str. 16, sij. 2023, doi: 10.1186/s12911-023-02114-6.

[6] „Deep Learning for MRI Brain Tumor Classification - European Society of Medicine“. Pristupljeno: 15. siječanj 2026. Dostupno na: https://esmed.org/deep-learning-for-mri-brain-tumor-classification/

[7] G. Mahesh i Y. M, „Brain Tumor Detection and Classification Using MRI Images“, *International Journal for Research in Applied Science and Engineering Technology*, sv. 12, str. 856–863, lis. 2024, doi: 10.22214/ijraset.2024.64719.

[8] M. A. Khan i R. B. Z. Auvee, „Comparative Analysis of Resource-Efficient CNN Architectures for Brain Tumor Classification“, 23. prosinac 2024., *arXiv*: arXiv:2411.15596. doi: 10.48550/arXiv.2411.15596.

[9] M. S. Chowdhury, S. F. Tanzim, S. Banerjee, I. A. Mamoon, i A. M. Islam, „Squeezed-Eff-Net: Edge-Computed Boost of Tomography Based Brain Tumor Classification leveraging Hybrid Neural Network Architecture“, 08. prosinac 2025., *arXiv*: arXiv:2512.07241. doi: 10.48550/arXiv.2512.07241.